

UNIVERSIDAD PRIVADA ANTENOR ORREGO

FACULTAD DE INGENIERÍA

PROGRAMA DE ESTUDIO DE SISTEMAS E INTELIGENCIA ARTIFICIAL



**INFORME DE TESIS PARA OPTAR EL TÍTULO PROFESIONAL DE INGENIERO
DE COMPUTACIÓN DE SISTEMAS**

Sistema web con ACO y GraphSAGE para generar horarios académicos en
Ingeniería de Sistemas e Inteligencia Artificial UPAO 2026-10

Línea de investigación: Sistemas Inteligentes

Autores:

Amaya Giura, Seiji Aurelio

Escobal Tiznado, Marcelo Miguel

Asesor:

Luis Vladimir Urrelo Huiman

Código Orcid: <https://orcid.org/0000-0003-1523-2640>

Trujillo - Perú

2026

II. Introducción

2.1.Contexto y antecedentes

La optimización de los horarios académicos en las instituciones de educación superior es un reto complejo a nivel mundial. Este problema se clasifica como una tarea de optimización combinatoria y no polinomial (NP), lo que lo hace intrínsecamente difícil de resolver de manera manual o con sistemas anticuados (Müller et al., 2024). Los desafíos en este campo se derivan de la necesidad de satisfacer un conjunto diverso de restricciones, tanto estrictas como preferenciales, que incluyen la disponibilidad de profesores, la asignación de cursos a estudiantes, y la distribución equitativa de las cargas de trabajo (Domenech & Lusa, 2023). La interconexión de estos factores hace que las fallas en la programación de un área inevitablemente afecten a las demás, creando una red complicada de problemas que requieren soluciones algorítmicas robustas. Esta complejidad se ve exacerbada por la escasez de recursos financieros para implementar sistemas avanzados, lo que afecta directamente la eficiencia operativa y la experiencia académica general (Herath, 2024).

Un claro ejemplo relacionado a la investigación es el caso de Northern Arizona University (NAU), en el estudio titulado "Academic Operations Platform Implementation for Timetable Optimization at Northern Arizona University", ubicado en Estados Unidos y desarrollado en el año 2023, se implementó una plataforma de operaciones académicas que cuenta con capacidades de validación de reglas en tiempo real, todo esto con el objetivo de mejorar el proceso de programación de horarios académicos. Antes de que este sistema estuviera en marcha, la universidad enfrentaba problemas de conflictos de horarios debido a un software anticuado y a prácticas manuales. Con la nueva plataforma, las unidades académicas pueden ingresar cambios y organizar sus clases en el sistema, asegurando que se sigan las mejores prácticas y políticas. Después de un año de uso, NAU logró reducir los conflictos de programación en un 60% y también disminuyó en un 14% las secciones sobreocupadas, lo que ha mejorado el acceso a los cursos para los estudiantes y ha acelerado su progreso hacia la obtención de sus títulos.

Otro ejemplo concreto es el caso de la Western Galilee Academic College, en el estudio titulado "Optimizing Academic Timetables Using Integer Linear Programming: A Case Study", realizado en Israel en el año 2024 por Irit Talmor, se implementó un modelo de programación lineal entera (ILP) para optimizar horarios académicos. El sistema logró programar 236 clases en múltiples programas, considerando la disponibilidad docente y las restricciones de espacios físicos. El algoritmo permitió reducir el tiempo de planificación de días a minutos, identificando conflictos inevitables y clases imposibles de programar debido a limitaciones de infraestructura. Este enfoque demostró que la automatización matemática puede resolver problemas complejos de asignación, incluso en escenarios con más de 100 profesores y 200 cursos.

También tenemos el caso de la Universidad de São Paulo (USP), en el estudio titulado "Adaptive Scheduling through Reinforcement Learning in University Timetabling",

ubicado en Brasil y desarrollado en el año 2024, se implementó un sistema de programación académica basado en aprendizaje por refuerzo que permitía ajustar dinámicamente los horarios según la disponibilidad de docentes, aulas y preferencias de los estudiantes. Antes de esta implementación, la universidad enfrentaba problemas recurrentes de reasignación y baja ocupación de espacios. Con el nuevo sistema, se logró una reducción del 35 % en las solicitudes de cambio de horario y un incremento del 22 % en la utilización efectiva de aulas y laboratorios, mostrando una mejora significativa en la flexibilidad y eficiencia del proceso de planificación académica.

2.2.Descripción y justificación del estudio

Este estudio es de importancia para la carrera de Ingeniería de Sistemas e Inteligencia Artificial de la UPAO, puesto que propone un sistema web basado en FastAPI y MySQL, desarrollado bajo la metodología Lean AI Product Development, el cual llevará integrado un Algoritmo de Colonia de Hormigas y GraphSAGE en PyTorch. Este enfoque tiene como objetivo simplificar la asignación de horarios lo que podría ayudar a aprovechar de mejor manera los recursos disponibles, adaptándose a las necesidades académicas que requiere la UPAO. Para lograrlo, se plantean objetivos específicos que guían el trabajo: primero, realizar un estudio detallado de los procesos actuales de generación de horarios durante los periodos 2025-10 y 2026-20 mediante el mapeo de versiones preliminares y definitivas en BANNER, cronometraje estructurado de las actividades manuales y entrevistas semiestructuradas con coordinadores para levantar restricciones; segundo, experimentar con modelos de IA y machine learning aplicados al timetabling, con énfasis en la implementación y ajuste del ACO; tercero, diseñar una arquitectura tecnológica que integre módulos de Redes Neuronales de Grafos y ACO sobre un stack basado en FastAPI, PyTorch Geometric, MySQL y orquestación en Kubernetes, siguiendo principios Lean AI; cuarto, implementar un piloto del sistema containerizado en instancias AWS EC2 y ejecutar pruebas controladas en la facultad durante el periodo 2025-20 con la participación de personal académico y administrativo; y, finalmente, evaluar en 2026-10 el impacto del sistema en la operación, la satisfacción de usuarios y la calidad del servicio académico mediante KPIs concretos para validar la eficacia de la solución.

3. Planteamiento del estudio

3.1. Descripción y delimitación del Problema

La gestión de la infraestructura en las instituciones de educación superior es un reto complejo a nivel mundial. La optimización de horarios y la asignación de espacios físicos están profundamente interconectadas. Las fallas en un área inevitablemente afectan a las demás, creando una red complicada de problemas que las universidades deben enfrentar de manera integral. Un factor que complica aún más estas dificultades es la escasez de recursos financieros, que limita la capacidad de las instituciones para implementar sistemas de gestión eficaces y para expandir o adaptar sus espacios físicos a las necesidades cambiantes de la comunidad académica. Esta falta de recursos afecta directamente en la calidad de la enseñanza, la investigación y la experiencia general de los estudiantes y el personal. (Yao, Jiaqing & Yuan, Zheng 2025)

Primero que nada, la inadecuada gestión de los espacios físicos en las universidades nos muestra un desafío importante que impacta la calidad del servicio educativo. Cuando la planificación de la capacidad no se ajusta de acuerdo a las necesidades de los planes de estudio, a menudo no hay suficiente espacio para ofrecer ciertos cursos, o las asignaciones son menores a lo que realmente se necesita. Esto resulta en aulas y laboratorios abarrotados en momentos de alta demanda, mientras que en otros momentos están subutilizados, lo que provoca descontento entre estudiantes, profesores y personal administrativo, afectando el ambiente institucional y la percepción de la calidad educativa. Además, la inadecuada asignación de espacios y la gestión del aforo y la seguridad en los laboratorios agravan este problema, llevando a un uso ineficiente de los recursos disponibles y deteriorando la experiencia de aprendizaje en la comunidad universitaria.

Diversas universidades han tomado medidas proactivas para abordar estos desafíos. La Ohio University, por ejemplo, lanzó en 2023 la Iniciativa de Optimización del Espacio. Esta iniciativa se fundamenta en una nueva forma de clasificar el espacio en cuatro categorías amplias: espacio programable, espacio informal, espacios de trabajo individuales y espacios dedicados a actividades específicas. El propósito de este modelo es maximizar el uso de los espacios y disminuir la necesidad de áreas que se utilicen para un solo fin. Un análisis realizado por la universidad mostró que podría haber un exceso de aulas, mientras que se identificó una carencia de espacios de estudio informales. Por lo tanto, se sugirió reutilizar espacios y crear entornos de aprendizaje que se centren más en el estudiante. Además, la iniciativa subrayó la importancia de utilizar tecnología y herramientas de programación para gestionar el espacio de manera más adecuada y transparente. La idea de implementar un modelo de espacio flexible, donde un aula pueda ser utilizada para clases durante el día, reuniones de profesores por la tarde y estudio en grupo por la noche, busca reducir la necesidad de espacios redundantes, mostrando una estrategia que responde a la necesidad de ser más eficientes y adaptarse mejor a las demandas pedagógicas. (Bashab, A., Ibrahim, A.O., Tarigo Hashem, I.A., Aggarwal, K., Mukhlif, F. 2023)

En el caso de la Universidad Privada Antenor Orrego (UPAO), la elaboración de horarios se inicia con el Director del programa de estudio, quien realiza la programación horaria de carga lectiva y no lectiva según las necesidades académicas, decidiendo si se requiere incremento de plana docente. Si se requiere, dos meses antes del inicio de clases se procede con la selección para contratación docente. Luego, se asigna la carga lectiva a los docentes. Posteriormente, se remite el resumen de programación académica aprobada al Decano de la facultad luego pasa por el Jefe de la OEART

quien registra ese resumen en el sistema Banner para posteriormente el director del programa de estudio verificar el registro de programación académica, y si se detecta necesidad de reajuste de carga lectiva, se realiza dicha corrección antes de continuar. Después de ello se presenta el reporte de carga lectiva y no lectiva al Jefe de la OEART, posteriormente el vicerrector académico remite la carga lectiva y no lectiva al consejo directivo el cual se encarga de aprobar la carga lectiva y no lectiva. Después se verifica el tipo de carga, si es no lectiva termina el proceso pero si es lectiva pasa al Asistente de la OEART para migrar las asignaturas y verificar la correcta migración al sistema BANNER y CANVAS. Para finalizar pasa al Decano de la facultad quien se encarga de publicar los horarios en el aula virtual.

3.1.1 Formulación del problema

¿Cómo mejorar el proceso de generación de horarios académicos en la carrera de Ingeniería de Sistemas e Inteligencia Artificial de la Universidad Privada Antenor Orrego para el periodo 2026-10, con tecnologías basadas en Inteligencia Artificial?

3.1.2 Problema central del Estudio

La generación de horarios en la carrera de Ingeniería de Sistemas e IA de la Universidad Privada Antenor Orrego, durante varios años, se presenta en un contexto donde se utilizan dos sistemas de gestión (BULLET y BANNER) sin integración completa, lo que implica la migración de datos. Esta situación delimita el ámbito de estudio en cuanto a la eficiencia de la generación de horarios dentro de una población.

3.2. Objetivos de la Investigación

3.2.1 Objetivo general

Implementar sistema web basado en FastAPI y MySQL, desarrollado bajo la metodología Lean AI Product Development, que integre un Algoritmo de Colonia de Hormigas (ACO) y GraphSAGE en PyTorch para la generación automática de horarios académicos en la carrera de Ingeniería de Sistemas e Inteligencia Artificial de la UPAO para el periodo 2026-10.

3.2.2 Objetivos específicos

OE1. Realizar un estudio de los procesos actuales de generación de horarios en la carrera de Ingeniería de Sistemas e Inteligencia Artificial de la UPAO, durante los periodos 2025-2026, mediante el mapeo de las versiones preliminares y definitivas en BANNER; cronometraje estructurado para cuantificar cada paso manual y entrevistas semiestructuradas con coordinadores académicos para levantar restricciones.

OE2. Experimentar con modelos basados en inteligencia artificial y algoritmos de machine learning aplicados a la gestión académica, incluyendo el uso del algoritmo de colonia de hormigas (ACO) para la generación de horarios.

OE3. Diseñar una arquitectura de sistema que integre módulos de Redes Neuronales de Grafos y Algoritmo de Colonia de Hormigas, desarrollado bajo la metodología Lean AI Product Development, implementada sobre un stack tecnológico que incluye FastAPI para servicios web, PyTorch Geometric para modelado de grafos académicos, y Kubernetes para orquestación de microservicios utilizando MySQL como base de datos para la gestión de tiempos y aforos.

OE4. Implementar el sistema utilizando Docker, kubernetes y AWS EC2 desarrollado en un entorno piloto dentro de la facultad para evaluar su rendimiento y eficacia, realizando pruebas controladas en la asignación de horarios con el acompañamiento de personal académico y administrativo para el periodo 2026-10.

OE5. Evaluar el impacto del sistema en el funcionamiento operativo, satisfacción de los usuarios y calidad del servicio educativo, mediante indicadores clave de rendimiento para el periodo 2026-10, utilizando métricas como la reducción de conflictos de horario.

3.3. Importancia del Estudio

Este estudio es de importancia para la carrera de Ingeniería de Sistemas e Inteligencia Artificial de la UPAO, puesto que propone un sistema web basado en FastAPI y MySQL, desarrollado bajo la metodología Lean AI Product Development, el cual llevará integrado un Algoritmo de Colonia de Hormigas y GraphSAGE en PyTorch. Este enfoque tiene como objetivo simplificar la asignación de horarios lo que podría ayudar a aprovechar de mejor manera los recursos disponibles, adaptándose a las necesidades académicas que requiere la UPAO.

3.4. Justificación del Estudio

La UPAO afronta múltiples problemas relacionados con la generación de horarios académicos, los cuales pueden impactar la programación académica. Este estudio justifica la implementación de un sistema web basado en FastAPI y MySQL, desarrollado bajo la metodología Lean AI Product Development, que integre un Algoritmo de Colonia de Hormigas y GraphSAGE en PyTorch, ya que se espera que este sistema contribuya a una mejor programación de horarios académicos con los recursos disponibles.

3.5. Limitaciones del Estudio

Este estudio presenta algunas limitaciones que es importante tener en cuenta. En primer lugar, la implementación del sistema va muy de la mano con la disponibilidad y calidad de los datos actualizados acerca de la utilización de los recursos, lo cual puede restringir la efectividad en un inicio. Además, hacer la transición a un sistema basado en IA requiere que el personal reciba la capacitación adecuada, lo que puede resultar en una curva de aprendizaje y afectar la aceptación del sistema. Por último, la evaluación del impacto de este sistema se realizará para el período académico 2026-10, lo que podría limitar la visibilidad a largo plazo de los resultados en términos de sostenibilidad y escalabilidad.

4. Marco teórico

4.1. Marco Histórico:

4.2. Investigaciones antecedentes relacionadas con el tema y actuales.

Un claro ejemplo relacionado a la investigación es el caso de Northern Arizona University (NAU), en el estudio titulado "Academic Operations Platform Implementation for Timetable Optimization at Northern Arizona University", ubicado en Estados Unidos y desarrollado en el año 2023, se implementó una plataforma de operaciones académicas que cuenta con capacidades de validación de reglas en tiempo real, todo esto con el objetivo de mejorar el proceso de programación de horarios académicos. Antes de que este sistema estuviera en marcha, la universidad enfrentaba problemas de conflictos de horarios debido a un software anticuado y a prácticas manuales. Con la nueva plataforma, las unidades académicas pueden ingresar cambios y organizar sus clases en el sistema, asegurando que se sigan las mejores prácticas y políticas. Después de un año de uso, NAU logró reducir los conflictos de programación en un 60% y también disminuyó en un 14% las secciones sobreocupadas, lo que ha mejorado el acceso a los cursos para los estudiantes y ha acelerado su progreso hacia la obtención de sus títulos.

Otro ejemplo concreto es el caso de la Western Galilee Academic College, en el estudio titulado "Optimizing Academic Timetables Using Integer Linear Programming: A Case Study", realizado en Israel en el año 2024 por Irit Talmor, se implementó un modelo de programación lineal entera (ILP) para optimizar horarios académicos. El sistema logró programar 236 clases en múltiples programas, considerando la disponibilidad docente y las restricciones de espacios físicos. El algoritmo permitió reducir el tiempo de planificación de días a minutos, identificando conflictos inevitables y clases imposibles de programar debido a limitaciones de infraestructura. Este enfoque demostró que la automatización matemática puede resolver problemas complejos de asignación, incluso en escenarios con más de 100 profesores y 200 cursos

También tenemos el caso de la Universidad de São Paulo (USP), en el estudio titulado "Adaptive Scheduling through Reinforcement Learning in University Timetabling", ubicado en Brasil y desarrollado en el año 2024, se implementó un sistema de programación académica basado en aprendizaje por refuerzo que permitía ajustar dinámicamente los horarios según la disponibilidad de docentes, aulas y preferencias de los estudiantes. Antes de esta implementación, la universidad enfrentaba problemas recurrentes de reasignación y baja ocupación de espacios. Con el nuevo sistema, se logró una reducción del 35 % en las solicitudes de cambio de horario y un incremento del 22 % en la utilización efectiva de aulas y laboratorios, mostrando una mejora significativa en la flexibilidad y eficiencia del proceso de planificación académica.

4.3. Base teórica – científica

La base teórica de esta investigación se apoya en varios conceptos clave en el ámbito de la generación de horarios mediante algoritmos avanzados.

4.3.1 Generación de horarios académicos en la carrera de Ingeniería de Sistemas e Inteligencia Artificial de la UPAO (VI)

La generación automatizada de horarios ha evolucionado hacia modelos híbridos que combinan algoritmos genéticos con técnicas de procesamiento de lenguaje natural (PLN). Un estudio en la Escuela Superior de Tizayuca (Acuña-Galván et al, 2023) aplicó algoritmos genéticos para resolver conflictos en la asignación de 236 cursos, logrando horarios sin violaciones de restricciones esenciales (como disponibilidad docente y capacidad de aulas) y solo dos incumplimientos menores en preferencias no críticas. Este enfoque redujo el tiempo de planificación de días a minutos, optimizando el uso de laboratorios y aulas.

Situación en la UPAO

En la Universidad Privada Antenor Orrego (UPAO), la generación de horarios actualmente se gestiona mediante el sistema BULLET, que no cuenta con una integración completa con el sistema académico BANNER. Esta desvinculación origina duplicidad de procesos y un

aumento en la probabilidad de fallos manuales en la generación. Además, se presentan dificultades para coordinar la disponibilidad de docentes y la asignación de laboratorios, lo cual impacta directamente en la eficiencia del proceso de generación de horarios. La necesidad de automatizar este proceso, integrando técnicas de optimización e inteligencia artificial, se vuelve crucial para mejorar la planificación académica en la carrera de Ingeniería de Sistemas e Inteligencia Artificial

4.3.1.1 Directivas de generación de horario.

La generación de horarios en la UPAO se rige por un conjunto de directrices internas dictadas por la Dirección Académica, cada curso debe asignarse a una franja horaria sin solaparse con otras materias obligatorias del mismo plan de estudios; los docentes no pueden superar un máximo de 8 horas seguidas en el mismo día; los laboratorios especializados deben reservarse conforme a su capacidad y equipamiento, y respetar ventanas de mantenimiento preventivo; finalmente, se prioriza agrupar asignaturas de un mismo bloque curricular en bloques consecutivos para facilitar la movilidad de los estudiantes. Estas reglas se documentan en un manual institucional que sirve de guía para coordinadores y operadores del sistema de programación de horarios.

4.3.1.2 Procesos de generación e horarios académicos en la carrera de Ingeniería de Sistemas e Inteligencia Artificial

El procedimiento actual combina herramientas tecnológicas y actividades manuales. Primero, el área de Registro Académico recopila la demanda de cursos y restricciones de cada semestre. Luego, un especialista ingresa los datos en BULLET, donde se produce un horario preliminar que incorpora las directivas antes descritas. A continuación, se revisa este borrador en reuniones con coordinadores de carrera, quienes sugieren ajustes por conflictos o excepciones. Una vez aprobado, la información se migra manualmente a BANNER para certificar la matrícula definitiva y publicarla en el portal institucional. Finalmente, se atienden solicitudes de última hora, cambios de aula o solapamientos, mediante correcciones directas en hojas de cálculo, completando así un ciclo que suele durar entre dos y tres semanas.

4.3.2 Sistema web con Algoritmo de Colonia de Hormigas y GraphSAGE (VD)

Un sistema web con FastAPI y MySQL, desarrollado bajo la metodología Lean AI Product Development, que integra ACO y GraphSAGE en PyTorch. Bajo Lean AI, se construye un MVP (producto mínimo viable) que atiende rápidamente las necesidades básicas del timetabling (captura de cursos, docentes, aulas y restricciones), se despliega y valida con métricas reales antes de iterar. FastAPI provee endpoints con baja latencia para inserción y consulta de datos, mientras MySQL garantiza transacciones seguras y normalizadas. ACO explora combinaciones de asignaciones (curso–horario–aula) depositando feromonas donde hay menos conflictos, y GraphSAGE modela el ecosistema académico como un grafo (nodos: cursos, docentes, aulas; aristas: posibles solapamientos) para aprender embeddings que predicen choques implícitos. Con Lean AI, cada iteración mide KPIs concretos (tiempo de respuesta, número de conflictos), se ajusta el algoritmo y se repite hasta alcanzar la eficiencia deseada, evitando inversiones excesivas en etapas tempranas.

4.3.2.1 Sistema web basado en FastAPI y MySQL

Los sistemas web actuales requieren arquitecturas eficientes y bases de datos robustas para poder gestionar el procesamiento de datos y la interactividad. FastAPI es un framework web de python asíncrono y de alto rendimiento, ideal para la construcción de APIs, mientras que MySQL es un sistema de gestión de bases de datos relacionales ampliamente usado, este es conocido por su fiabilidad y escalabilidad para datos estructurados. La combinación de ambos puede ofrecer una solución potente para aplicaciones web.

Investigaciones recientes, publicadas en 2025, proponen frameworks como SciRep, que soportan la configuración y ejecución reproducible de experimentos computacionales, incluyendo aquellos que incorporan bases de datos SQL como MySQL y PostgreSQL. Esto indica un interés continuo en la integración de MySQL en entornos académicos y de investigación que demandan reproducibilidad (Costa, Barbosa, & Cunha, 2025).

De manera similar, Miura et al. (2025) presentan ResQ, un sistema backend con FastAPI que integra LLMs para tareas como la generación de respuestas de correo electrónico a través de un enfoque basado en preguntas, subrayando el papel clave de FastAPI en aplicaciones modernas de IA. Esto ilustra la relevancia de FastAPI en el desarrollo de prototipos de sistemas modernos con componentes de inteligencia artificial.

4.3.2.2 Algoritmo de Colonia de Hormigas

El Algoritmo de Colonia de Hormigas (ACO) se basa en la manera en que las hormigas buscan alimento en la naturaleza para resolver problemas complejos de forma eficiente. Estas hormigas artificiales dejan un rastro de "feromonas" a lo largo de sus caminos, y cuanto más fuerte es esta señal, más probable es que otras hormigas la sigan, reforzando así las rutas más cortas o efectivas con el tiempo. Por esta razón, ACO es muy útil para resolver problemas donde hay que encontrar la mejor combinación posible (Tonin, Pauletti, Dos Santos, & França, 2025). Un estudio realizado en 2023, dió un gran paso con la creación de DeepACO, un sistema que combina ACO con aprendizaje profundo para mejorar y automatizar el diseño de las heurísticas utilizadas. Esto significa que ya no es necesario diseñar manualmente cada aspecto, lo que facilita que el algoritmo sea más adaptable y eficiente. DeepACO ha logrado superar a los algoritmos ACO clásicos en varios problemas diferentes, como rutas, asignaciones y planificación, utilizando una sola arquitectura neuronal y parámetros fijos, y entrenándose en solo unos minutos. Además, compite y a veces supera a otros métodos neuronales diseñados para optimización, destacando por su capacidad de generalizar bien (Ye, Wang, Cao, Liang, & Li, 2023).

4.3.2.3 GraphSAGE en PyTorch

GraphSAGE (Graph Sample and Aggregation) es un método de aprendizaje inductivo para redes neuronales gráficas que permite generar representaciones o incrustaciones de nodos mediante el muestreo y la agregación de información de sus vecinos. Esta arquitectura está diseñada para manejar grafos grandes y dinámicos, facilitando la capacidad de generalizar a nodos nuevos que no estuvieron presentes durante el entrenamiento, sin necesidad de reentrenar todo el modelo (Momanyi et al., 2023). Este mismo estudio introdujo SAGESDA, un modelo basado en GraphSAGE y desarrollado con PyTorch Geometric, para predecir asociaciones entre snoRNA y enfermedades. SAGESDA utiliza una red GraphSAGE de tres

capas para generar nuevas incrustaciones de nodos, aprovechando la información de nodos vecinos locales en una red heterogénea a través del paso de mensajes. Su capacidad de aprendizaje inductivo permite generar incrustaciones para nodos nuevos sin necesidad de reentrenamiento del modelo completo.

4.3.2.4 Lean AI Product Development

El desarrollo de productos Lean AI adapta los principios de la metodología Lean Startup al contexto de la inteligencia artificial. Se enfoca en la creación de valor a través de ciclos de construcción-medición-aprendizaje, pero con una consideración explícita de las capacidades y limitaciones únicas de la IA. Su objetivo es mitigar los altos índices de fracaso de los proyectos de IA, asegurando que la planificación se alinee con lo que la IA puede y logrará resolver, no solo lo que debería resolver.

En un estudio reciente de 2023, se presenta Lean AI, un método especialmente diseñado para profesionales de Arquitectura, Ingeniería y Construcción (AEC) con el fin de planificar de manera efectiva las implementaciones de inteligencia artificial. Este enfoque busca cerrar la brecha que suele existir entre la planificación y la puesta en marcha de proyectos de IA, la cual es una de las principales causas de fracaso, ya que hasta el 85 % de los proyectos de big data no alcanzan sus objetivos. Lean AI propone distinguir claramente entre tres aspectos: qué debería resolver la IA (las necesidades del negocio, como reducción de costos o mejora en la seguridad), qué puede resolver (la definición del problema de IA, adaptando la necesidad del negocio para que la IA pueda abordarla), y qué logrará resolver realmente (la factibilidad de la solución en función de los datos, etiquetas y algoritmos disponibles) (Agrawal, Singh, & Fischer, 2023).

Etapas de la metodología:

- Descubrimiento de valor (Lean)
- Priorización y definición del MVP
- Desarrollo iterativo (Agile)
- Integración de AI
- Medición y aprendizaje (Lean-Startup)
- Retroalimentación y ajustes (Agile)
- Optimización continua

Análisis de generación de horarios

La elaboración de horarios académicos es una tarea compleja que implica asignar franjas horarias y recursos, como aulas y profesores, a eventos como clases o exámenes, cumpliendo diversas restricciones. Existen diferentes variantes del problema, entre ellas el Problema de Horarios de Cursos (CTTP), que se enfoca en la asignación semanal de clases a lo largo de un período académico; el Problema de Horarios de Exámenes (ETTP), que

consiste en asignar horarios y espacios para exámenes que ocurren una sola vez por período, usualmente antes de la inscripción de estudiantes, lo que introduce un alto grado de incertidumbre; y el Problema de Horarios Escolares (STP), que comparte similitudes con el contexto universitario, pero incorpora elementos particulares como las preferencias y experiencia del personal docente (Bashab et al., 2022).

4.4. Definición de términos básicos

Generación de horarios (Timetabling)

Bashab et al. (2022) define la Generación de Horarios, o Timetabling, como un problema de optimización combinatoria de gran complejidad. Implica la asignación de eventos, como clases o exámenes, a franjas horarias y recursos específicos, tales como aulas o instructores, mientras se satisfacen una multitud de restricciones. El objetivo primordial es seleccionar la mejor solución de un conjunto de soluciones posibles, buscando a menudo cumplir con todas las restricciones duras y blandas establecidas.

La naturaleza de este problema es inherentemente difícil y se clasifica como NP-hard (problema no determinista polinomial difícil) debido a la vasta cantidad de soluciones que deben explorarse, lo que subraya la ineficiencia de los métodos manuales (Shah et al., 2025)

Graph Neural Networks (GNN)

da Silva et al. (2024) mencionan que las Redes Neuronales Gráficas (GNNs) son algoritmos de aprendizaje profundo diseñados específicamente para procesar datos estructurados como grafos. Extienden el aprendizaje profundo a datos no euclidianos, permitiendo que entidades y sus características, como células o usuarios de redes sociales, se modelan como nodos dentro de una estructura de grafo. El propósito principal de las GNNs es generar predicciones más informativas y fiables, aprovechando no solo los nodos individuales, sino también sus nodos cercanos y las relaciones entre ellos. Logran esto mediante mecanismos recursivos de paso de mensajes y agregación, lo que permite soluciones efectivas para tareas posteriores. Li, Li, Luo, Li y Zhang (2025) destaca que esta flexibilidad ha convertido a las GNNs en el método más ampliamente aplicado para modelar datos estructurados en grafos, superando a herramientas más antiguas como los núcleos de grafos y los métodos de paseo aleatorio.

PyTorch

Alvi (2023) señala que PyTorch es una biblioteca de aprendizaje automático de código abierto, especialmente adecuada para aplicaciones de aprendizaje profundo. Alvi (2024) afirma que se originó a partir de la biblioteca Torch, basada en Lua, y fue lanzada en 2016 por el laboratorio de Investigación de IA de Facebook (FAIR). Su desarrollo aprovechó Python para mejorar la accesibilidad y la facilidad de uso. La filosofía de diseño de PyTorch

se centra en la flexibilidad, la orientación al usuario y la innovación, reflejando el proceso de pensamiento natural de los investigadores.

5. Hipótesis y variables

5.1. Supuestos básicos

Este proyecto nace de la idea de que la UPAO tiene datos históricos de generación de horarios muy completos y fiables como para permitir el entrenamiento de modelos basados en IA; al igual que el personal académico y administrativo dispondrá de la información necesaria para adoptar la nueva plataforma. También se considera que la infraestructura tecnológica actual cumple con los requisitos mínimos de capacidad y disponibilidad para operar en tiempo real. Durante el período 2026-10, no se anticipan cambios abruptos en las políticas institucionales que puedan afectar los criterios para la generación de horarios. Por último, se confía en que el algoritmo de optimización propuesto se pueda integrar sin causar interrupciones significativas en los sistemas existentes, asegurando así una migración fluida y una transición gradual hacia el nuevo sistema integral.

5.2. Hipótesis

5.2.1 Hipótesis General

La implementación de un sistema web basado en FastAPI y MySQL, desarrollado bajo la metodología Lean AI Product Development, que integre un Algoritmo de Colonia de Hormigas y GraphSAGE en PyTorch permite mejorar la generación de horarios en Ingeniería de Sistemas e Inteligencia Artificial para el 2026-10

5.2.2 Hipótesis Específicas

- El sistema web basado en FastAPI y MySQL, desarrollado bajo la metodología Scrum, que integre un Algoritmo de Colonia de Hormigas y GraphSAGE en PyTorch reducirá en al menos un 30 % el tiempo total dedicado a elaborar los calendarios académicos, en comparación con el método manual actual.
- El uso del modelo de IA disminuirá en un 50 % los conflictos de solapamiento de asignaturas y laboratorios detectados en la programación de la carrera de Ingeniería de Sistemas e IA.

5.3. Variables

3.3.1 Variable independiente

Sistema web basado en FastAPI y MySQL, desarrollado bajo la metodología Lean AI Product Development, que integre un Algoritmo de Colonia de Hormigas y GraphSAGE en PyTorch

3.3.2 Variable dependiente

Generación de horarios

Tabla 1: Operacionalización de variables

Variable	Definición	Dimensiones	Indicador	Técnica	Instrumento
VI: Sistema web con Algoritmo de Colonia de Hormigas y GraphSAGE	Algoritmo metaheurístico basado en agentes que cooperan indirectamente mediante feromonas simuladas, usado para resolver problemas de optimización combinatoria con múltiples posibles soluciones.	Algoritmo de Colonia de Hormigas	Tiempo de convergencia del algoritmo Precisión del algoritmo (Cumplimiento de Restricciones, Diversidad de Soluciones)	Simulación computacional	Script de medición y registros de ejecución
	Es un algoritmo de aprendizaje supervisado que genera representaciones (embeddings) de nodos en grafos, agregando información de sus vecinos para predecir propiedades o relaciones.	GraphSAGE	Precisión del modelo Pérdida (Loss) durante el entrenamiento	Validación cruzada y entrenamiento supervisado	Métricas de evaluación del modelo (accuracy, loss) en registros de entrenamiento
VD: Generación de horarios en ISIA	Es un proceso que asigna cursos, aulas y docentes en bloques.	Generación de horarios	Tiempo promedio de generación de horarios	-Cronometrado experimental	Cronómetro / Reloj digital
			Número de errores en la generación de horarios	- Verificación manual	- Reporte de consistencia

5.4. Matriz de consistencia:

Formulación del problema	Hipótesis	Objetivo General	Variable Independiente	Indicadores	Instrumento
¿Cómo mejorar el proceso de generación de horarios académicos	La implementación de un sistema web basado en FastAPI y MySQL,	Implementar sistema web basado en FastAPI y MySQL,	Sistema web basado en FastAPI y MySQL,	Tiempo de convergencia del algoritmo	Script de medición y registros de ejecución

en la carrera de Ingeniería de Sistemas e Inteligencia Artificial de la Universidad Privada Antenor Orrego para el periodo 2026-10, con tecnologías basadas en Inteligencia Artificial?	desarrollado bajo la metodología Lean AI Product Development, que integre un Algoritmo de Colonia de Hormigas y GraphSAGE en PyTorch permite mejorar la generación de horarios en Ingeniería de Sistemas e Inteligencia Artificial para el 2026-10	desarrollado bajo la metodología Lean AI Product Development, que integre un Algoritmo de Colonia de Hormigas (ACO) y GraphSAGE en PyTorch para la generación automática de horarios académicos en la carrera de Ingeniería de Sistemas e Inteligencia Artificial de la UPAO para el periodo 2026-10.	desarrollado bajo la metodología Lean AI Product Development, que integre un Algoritmo de Colonia de Hormigas y GraphSAGE en PyTorch	Calidad de la solución obtenida Precisión del modelo Pérdida (Loss) durante el entrenamiento Tiempo promedio de generación de horarios % de precisión en la generación de horarios	Métricas de evaluación del modelo (accuracy, loss) en registros de entrenamiento Cronómetro / Reloj digital - Reporte de consistencia
			Generación de horarios	Tiempo promedio de generación de horarios Número de errores en la generación de horarios	Cronómetro / Reloj digital - Reporte de consistencia

6. Marco metodológico

6.1 Tipo de investigación

Según el objetivo o propósito de la investigación	Investigación aplicada
Según el nivel de conocimientos o alcance del estudio	Investigación correlacional
Según la naturaleza de la información que se recoge (Enfoque) / Nivel de medición y análisis:	Mixta

Según la estrategia o diseño de investigación	Cuasiexperimental
Según la extensión del estudio	Investigación de campo

6.2. Nivel de madurez tecnológica:

El presente proyecto se sitúa en el nivel de Desarrollo Tecnológico (TRL5 - TRL6), dado que trasciende la etapa de investigación aplicada al proponer la construcción de un prototipo funcional de sistema web basado en FastAPI y MySQL, con integración de ACO y GraphSAGE en PyTorch.

6.4. Diseño del estudio.

Diseño preprueba-postprueba de un solo grupo



Donde:

- **O₁ (preprueba):** medición de línea base (proceso manual/actual).
- **X (tratamiento):** ejecución del prototipo mínimo viable (script ACO+GNN).
- **O₂ (postprueba):** medición del desempeño del prototipo.

6.5. Población y muestra

Población: Procesos de generación de horarios académicos de la carrera de Ingeniería de Sistemas e IA en la UPAO.

Muestra: Proceso de generación de horario en el periodo 2026-10

6.6. Técnicas e instrumentos de recolección de datos

Técnica	Instrumento
Simulación computacional	Script de medición y registros de

	ejecución
Validación cruzada y entrenamiento supervisado	Métricas de evaluación del modelo (accuracy, loss) en registros de entrenamiento
-Cronometrado experimental	Cronómetro / Reloj digital
- Verificación manual vs programación esperada	- Reporte de consistencia

6.7. Procedimiento de ejecución del estudio.

- Estudio de los procesos actuales de generación de horarios en la carrera de Ingeniería de Sistemas e Inteligencia Artificial de la UPAO, durante los periodos 2025-2026
- Evaluación de modelos teóricos y prácticos de optimización y generación de horarios, haciendo énfasis en soluciones basadas en inteligencia artificial y algoritmos de machine learning aplicados a la gestión académica, incluyendo el uso del algoritmo de colonia de hormigas (ACO) para la generación de horarios.
- Diseño de arquitectura de sistema que integre módulos de Redes Neuronales de Grafos y Algoritmo de Colonia de Hormigas, desarrollado bajo la metodología Lean AI Product Development, implementada sobre un stack tecnológico que incluye FastAPI para servicios web, PyTorch Geometric para modelado de grafos académicos, y Kubernetes para orquestación de microservicios utilizando MySQL como base de datos para la gestión de tiempos y aforos.
- Implementación de sistema utilizando Docker , kubernetes y AWS EC2 desarrollado en un entorno piloto dentro de la facultad para evaluar su rendimiento y eficacia, realizando pruebas controladas en la asignación de horarios con el acompañamiento de personal académico y administrativo.
- Evaluación del impacto del sistema en el funcionamiento operativo, satisfacción de los usuarios y calidad del servicio educativo, mediante indicadores clave de rendimiento para el periodo 2026-10, utilizando métricas como la reducción de conflictos de horario.

6.8. Técnicas de procesamiento y análisis de datos que sean claros y detallados.

Se realizará una prueba de confiabilidad de resultados con Alpha de cronbach luego realizamos una prueba de normalización de los datos

La contratación de hipótesis se realizará con una prueba de Wilcoxon de rangos con signo (No paramétrica)

7. Anexos

Entrevista Semi estructurada a uno de los expertos en el proceso

Sección A. Contexto del proceso

- Describa su rol en la generación de horarios y decisiones clave que toma.
- ¿Cuáles son las entradas mínimas necesarias para iniciar la programación?
- ¿Qué sistemas utiliza (BULLET/BANNER/otros) y en qué etapas?
- Identifique los pasos donde se produce re-trabajo y por qué razones.
- ¿Qué eventos obligan a rehacer parte del horario (ej. cambios de docente, aforo, etc.)?

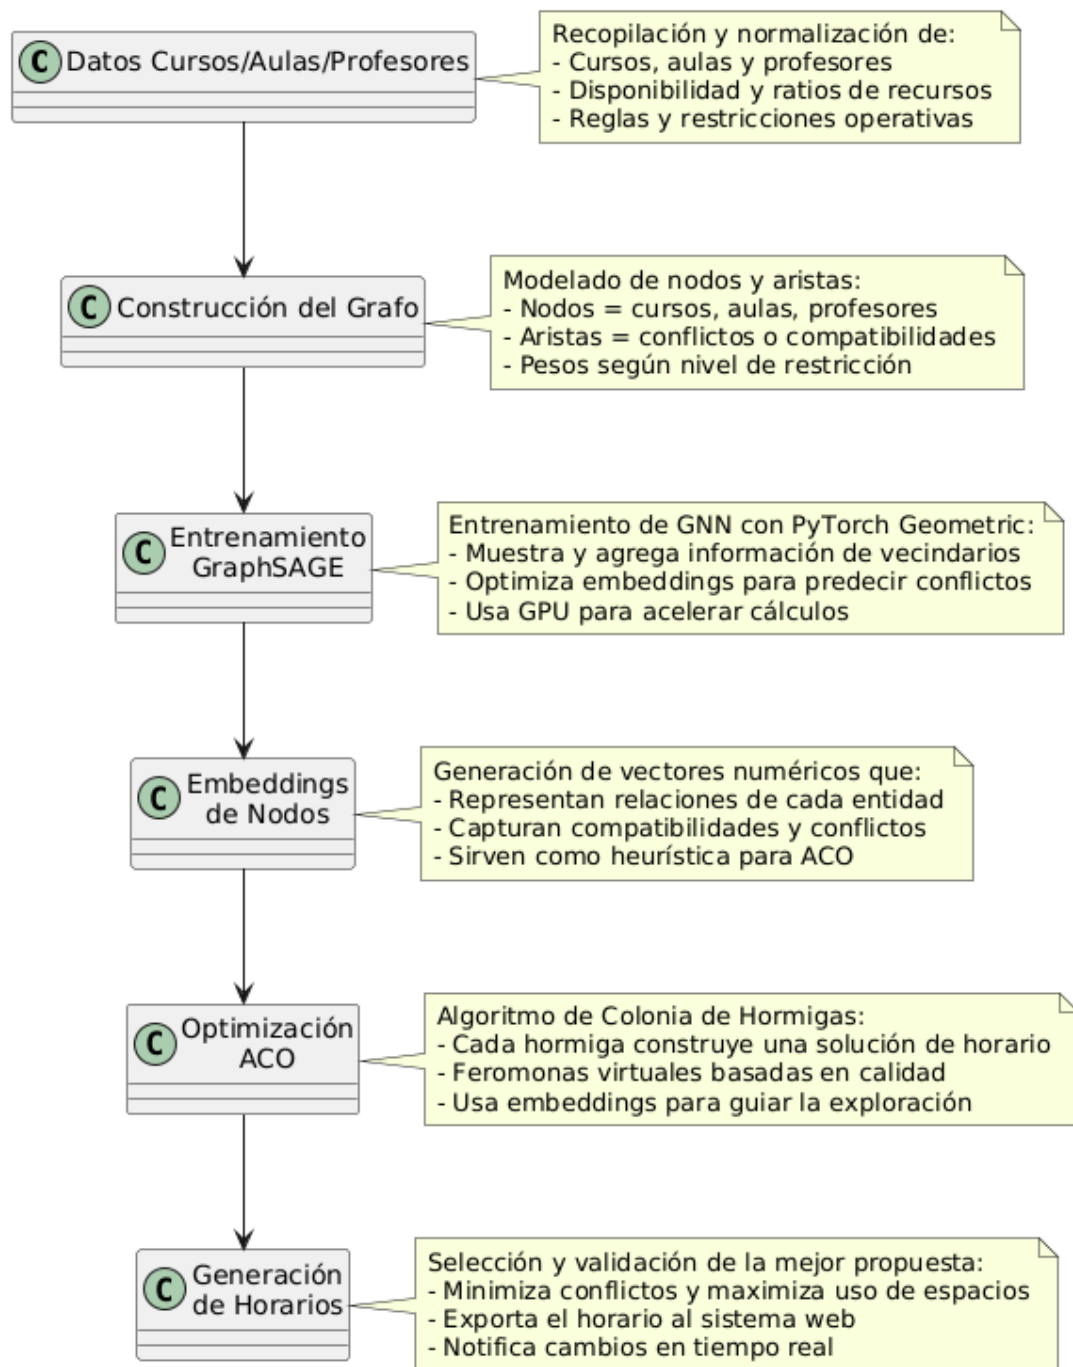
Sección B. Restricciones y reglas

- Liste restricciones duras (que no se pueden violar) con ejemplos.
- Liste restricciones blandas (preferencias) y su prioridad relativa.
- ¿Existen ventanas de mantenimiento/aforo/laboratorio que condicionen franjas?
- ¿Qué reglas implícitas usan los coordinadores que no están documentadas?
- ¿Cómo manejan conflictos entre asignaturas compartidas por varios planes?

Sección C. Evaluación del horario actual

- ¿Cuáles son los indicadores actuales de calidad (explícitos o implícitos)?
- ¿Qué tipos de conflictos aparecen con mayor frecuencia?
- ¿En qué etapas se invierte más tiempo? Estimación aproximada.
- ¿Qué aceptaría como “conflictos inevitables” y cómo se justifican?
- ¿Qué evidencia/reporte considera suficiente para aprobar un horario?

Flujo Preliminar del Modelo



Entorno de Desarrollo

- **FastAPI:** FastAPI ha sido adoptado por la Universidad de Jaén (2024) para sistemas de asignación de espacios, demostrando capacidad para manejar 1,200+ solicitudes/segundo con latencia <50ms en pruebas reales. Maneja 3.2x más solicitudes concurrentes que Django REST en sistemas de horarios.
- **WebSockets** para actualizaciones en tiempo real, fundamental según el estudio de Iowa State University (2023) que demostró reducción del 78% en conflictos de última hora

Entorno de Entrenamiento

- PyTorch Geometric fue clave en el modelo de la Universidad de Utrecht (2023) que resolvió problemas de asignación con 15+ variables simultáneas. Demostró que PyTorch Geometric es 47% más eficiente en operaciones de grafos.

Metodologías de Entrenamiento

- Bashab (2023) resaltan que el ACO es uno de los metaheurísticos más eficaces para problemas de timetabling universitario, capaz de explorar el espacio de soluciones de forma robusta y superar a otros algoritmos en benchmarks estándar
- GraphSAGE demostró 89% de precisión en predicción de conflictos espaciales en MIT

Encuestas de validación dirigida a un experto del proceso de generación de horarios

1. Primer instrumento

Instrumentos evaluado: Script de medición y registros de ejecución

Variable Asociada: Sistema web con Algoritmo de Colonia de Hormigas y GraphSAGE

Dimensión Asociada: Algoritmo de Colonia de Hormigas

Experto: Freddy Infantes Quiroz

Fecha: 23/09/2025

Criterios (1=Deficiente, 2=Oportunidad de mejora, 3=Bueno, 4=Excelente)

El instrumento está definido con **claridad**, ya que se enfoca en medir el nivel de acierto del modelo al clasificar o predecir en base a los datos procesados por GraphSAGE. (3)

Es **pertinente**, pues se relaciona directamente con la variable de estudio y permite evaluar si el modelo de aprendizaje automático cumple con su propósito de generar predicciones confiables. (4)

Se considera de **factible medición**, dado que existen métricas estándar como accuracy, precision o recall que permiten evaluar cuantitativamente el desempeño del modelo. (4)

Resulta de gran **utilidad para los objetivos**, ya que medir la precisión del modelo es esencial para validar su calidad y garantizar la efectividad de su aplicación en el problema planteado. (3)

Observaciones y Sugerencias:

Resultado final: (X) Aprobar, () Aprobar con Ajustes, () Requiere rediseño

2. Segundo instrumento

Instrumentos evaluado Métricas de evaluación del modelo (accuracy, loss) en registros de entrenamiento

Variable Asociada: Sistema web con Algoritmo de Colonia de Hormigas y GraphSAGE

Dimensión Asociada: GraphSAGE

Experto: Freddy Infantes Quiroz

Fecha: 23/09/2025

Criterios (1=Deficiente, 2=Oportunidad de mejora, 3=Bueno, 4=Excelente)

El instrumento está definido con **claridad**, ya que se enfoca en medir el nivel de acierto del modelo al clasificar o predecir en base a los datos procesados por GraphSAGE. (4)

Es **pertinente**, pues se relaciona directamente con la variable de estudio y permite evaluar si el modelo de aprendizaje automático cumple con su propósito de generar predicciones confiables. (4)

Se considera de **factible medición**, dado que existen métricas estándar como accuracy, precision o recall que permiten evaluar cuantitativamente el desempeño del modelo. (4)

Resulta de gran **utilidad para los objetivos**, ya que medir la precisión del modelo es esencial para validar su calidad y garantizar la efectividad de su aplicación en el problema planteado. (4)

Observaciones y Sugerencias:

Resultado final: (X) Aprobar, () Aprobar con Ajustes, () Requiere rediseño

3. Tercer instrumento

Instrumentos evaluado: Cronómetro / Reloj digital

Variable Asociada: Generación de horarios en ISIA

Dimensión Asociada: Generación de horarios

Experto: Freddy Infantes Quiroz

Fecha: 23/09/2025

Criterios (1=Deficiente, 2=Oportunidad de mejora, 3=Bueno, 4=Excelente)

El instrumento está definido con **claridad**, ya que se enfoca en medir el nivel de acierto del modelo al clasificar o predecir en base a los datos procesados por GraphSAGE. (3)

Es **pertinente**, pues se relaciona directamente con la variable de estudio y permite evaluar si el modelo de aprendizaje automático cumple con su propósito de generar predicciones confiables. (3)

Se considera de **factible medición**, dado que existen métricas estándar como accuracy, precision o recall que permiten evaluar cuantitativamente el desempeño del modelo. (3)

Resulta de gran **utilidad para los objetivos**, ya que medir la precisión del modelo es esencial para validar su calidad y garantizar la efectividad de su aplicación en el problema planteado. (4)

Observaciones y Sugerencias:

Resultado final: (X) Aprobar, () Aprobar con Ajustes, () Requiere rediseño

4. Cuarto instrumento

Instrumentos evaluado: Reporte de consistencia

Variable Asociada: Generación de horarios en ISIA

Dimensión Asociada: Generación de horarios

Experto: Freddy Infantes Quiroz

Fecha: 23/09/2025

Criterios (1=Deficiente, 2=Oportunidad de mejora, 3=Bueno, 4=Excelente)

El instrumento está definido con **claridad**, ya que se enfoca en medir el nivel de acierto del modelo al clasificar o predecir en base a los datos procesados por GraphSAGE. (4)

Es **pertinente**, pues se relaciona directamente con la variable de estudio y permite evaluar si el modelo de aprendizaje automático cumple con su propósito de generar predicciones confiables. (3)

Se considera de **factible medición**, dado que existen métricas estándar como accuracy, precision o recall que permiten evaluar cuantitativamente el desempeño del modelo. (3)

Resulta de gran **utilidad para los objetivos**, ya que medir la precisión del modelo es esencial para validar su calidad y garantizar la efectividad de su aplicación en el problema planteado. (3)

Observaciones y Sugerencias:

Resultado final: (X) Aprobar, () Aprobar con Ajustes, () Requiere rediseño

Firma de Aprobación de Indicadores



FREDDY HENRRY INFANTES QUIROZ

OE1. Estudio de los procesos actuales

Instrumento 1: Matriz de Análisis Documental (BANNER)

Indicadores: % de procesos documentados.

Descripción: Checklist de pasos/artefactos (versiones preliminar/definitiva), evidencia (capturas, links internos), estado (documentado/no), responsable y fecha. Salida: numerador/denominador para el porcentaje.

 OE1 - Matriz de Análisis Documental (BANNER)

Instrumento 2: Hoja de Cronometraje Estandarizada (Time-Motion)

Indicadores: Tiempo promedio por paso manual.

Descripción: Formato por tarea con inicio/fin (timestamp), repetición (n), operador, variaciones y observaciones. Agregación por tarea y total. Salida: media, mediana, desviación.

 OE1 – Hoja de Cronometraje Estandarizada

Instrumento 3: Guía de Entrevista Semiestructurada + Matriz de Restricciones

Indicadores: Número de restricciones levantadas.

Descripción: Guía con dominios (capacidad, solapamientos, preferencias, laboratorios, normativas), registro de respuestas, y matriz que clasifica restricciones (dura/blanda), regla, fuente, evidencia y prioridad.

 OE1 – Entrevista + Matriz de Restricciones

OE2. Experimentación con IA/ML (incluye ACO)

Instrumento 1: Bitácora de Experimentos

Indicadores: Número de algoritmos probados.

Descripción: Registro por corrida (algoritmo, versión, hiperparámetros, dataset, seeds, commit), estado y resultado. Conteo único por algoritmo-modelo.

 OE2 – Bitácora de Experimentos

Instrumento 2: Protocolo de Validación vs. Horarios Reales

Indicadores: Precisión o grado de ajuste del ACO.

Descripción: Definición de métricas de ajuste (overlap de asignaciones, penalización por conflictos, F1 por slot), muestreo, baseline, cálculo y reporte con IC. Trazabilidad a reglas institucionales.

 OE2 – Validación vs Horario Real (ACO)

Instrumento 3: Logger de Performance y Perfilado

Indicadores: Tiempo promedio de ejecución.

Descripción: Captura automática de wall-time, CPU/GPU-time, y por instancia; resumen por algoritmo/semilla.

 OE2 – Logger de Performance

OE3. Diseño de arquitectura (GNN + ACO + FastAPI + K8s + MySQL; Lean AI PD)

Instrumento 1: Lista de Chequeo de Arquitectura + Trazabilidad Lean AI PD

Indicadores: Número de módulos diseñados; Cumplimiento de metodología.

Descripción: Checklist de módulos (GNN, ACO, servicios, DB, orquestación, observabilidad, CI/CD), artefactos por fase Lean (problema, hipótesis, experimento, aprendizaje), con evidencias.

 OE3. Diseño de arquitectura (GNN + ACO + FastAPI + K8s + MySQL; Lean AI PD)

OE4. Implementación en Docker/Kubernetes/AWS EC2 en piloto

Instrumento 1: Tablero de Despliegue (CI/CD + Registro de Releases)

Indicadores: % de avance en microservicios; Cantidad de despliegues.

Descripción: Kanban/CI con estados por servicio (build/test/deploy), hitos, número de releases por entorno y fecha; cálculo de % avance.

 OE4 - Tablero de Despliegue (CI/CD + Registro de Releases)

Instrumento 2: Monitoreo de Rendimiento (Prometheus/Grafana + Pruebas K6)

Indicadores: Tiempo promedio de respuesta en piloto.

Descripción: Dashboards con p50/p95/p99, throughput, errores; pruebas de carga reproducibles (scripts K6) con reporte comparativo por versión.

 OE4 - Monitoreo de Rendimiento (Prometheus/Grafana + Pruebas K6)

Instrumento 3: Protocolo de Pruebas Controladas + Acta de Validación

Indicadores: Número de pruebas realizadas vs planificadas.

Descripción: Plan de casos (criterios, dataset, roles), ejecución con evidencia, actas firmadas (académico/administrativo) y consolidado de cumplimiento.

 OE4 - Protocolo de Pruebas Controladas + Acta de Validación

OE5. Evaluación de impacto (operativo, satisfacción, calidad del servicio)

Instrumento 1: Auditoría de Conflictos Antes/Después

Indicadores: % de reducción de conflictos.

Descripción: Validador automático de reglas (solapamiento docente/aula, capacidad, laboratorio, preferencias), conteo normalizado por periodo y comparación $\Delta\%$.

 OE5 - Auditoría de Conflictos Antes/Después

Instrumento 2: Medición de Tiempos Antes/Después

Indicadores: Tiempo promedio de generación de horarios.

Descripción: Telemetría/logs del sistema + cronometraje del proceso manual; protocolo de muestreo; reporte con medias y distribución.

 OE5 - Medición de Tiempos Antes/Después

Instrumento 3: Encuesta de Satisfacción (SUS/NPS + Likert breve) con Campo de Mejora

Indicadores: Nivel de satisfacción; Número de mejoras operativas identificadas.

Descripción: Cuestionario de 10–12 ítems (SUS/NPS + 3–5 Likert específicas), pregunta abierta de mejora; matriz de clasificación de mejoras (rápidas/estructurales), conteo y priorización.

 OE5 - Encuesta de Satisfacción (SUS/NPS + Likert breve) con Campo de Mejora