

OE2 — Instrumento 1: Matriz de Benchmarking y Justificación Científica del Modelo ACO

1. Datos personales

- **Responsable:** Amaya Giura Seiji, Escobal Tiznado Marcelo
- **Fecha:** 14/10/2025

2. Objetivo

-

3. Indicadores

-

4. Procedimiento

-

Componente de Diseño	Enfoque Clásico (ACO Tradicional)	Enfoque Propuesto (ACO + GraphSAGE)	Justificación y Análisis Científico	Referencias Clave	Consideraciones de Implementación y Recomendaciones
Representación del Problema	Grafo de construcción simple. La estructura de restricciones se maneja principalmente en la función heurística y en las comprobaciones de factibilidad.	Grafo heterogéneo que modela explícitamente entidades (Clases, Profesores, Aulas) y sus relaciones (restricciones) como nodos y aristas con atributos.	Las GNNs aprovechan la estructura relacional para aprender. Un grafo permite a la GNN capturar dependencias complejas que una heurística manual no puede. Análogo a problemas de JSSP y VRP donde la representación del grafo es clave para el éxito de los enfoques de aprendizaje. El enfoque propuesto de GNN-ACO demuestra la eficacia de los grafos heterogéneos para problemas de asignación.	Combinatorial Optimization and Reasoning with Graph Neural Networks, acceso: octubre 12, 2025, https://jmlr.org/papers/v24/21-0449.html BOOSTING NEURAL COMBINATORIAL OPTIMIZATION FOR LARGE-SCALE VEHICLE ROUTING PROBLEMS - OpenReview	La ingeniería de características y la definición de la topología del grafo son los pasos más críticos. Se recomienda un diseño modular que permita añadir/quitar tipos de nodos y aristas para adaptarse a diferentes variantes del UCTP.
Formulación de	Función matemática	La heurística	El diseño manual de	DeepACO:	El entrenamiento de la GNN es

Heurística (η)	diseñada manualmente. Requiere profundo conocimiento del dominio y sintonización de parámetros. A menudo es una aproximación local del coste de una decisión. Es el punto débil de ACO.	es aprendida por una GNN (GraphSAGE) . La GNN procesa el grafo del problema y el estado de la solución parcial para generar un valor heurístico para cada decisión posible.	heurísticas es laborioso y subóptimo. Frameworks como DeepACO demuestran que las GNNs pueden aprender heurísticas superiores que generalizan a través de múltiples problemas de optimización combinatoria, eliminando la necesidad de diseño manual. La GNN puede capturar información global y no local, superando las limitaciones de las heurísticas tradicionales.	Neural-enhanced Ant Systems for Combinatorial https://proceedings.neurips.cc/paper_files/paper/2023/file/883105b282fe15275991b411e6b200c5-Paper-Conference.pdf	un proceso offline computacionalmente intensivo. Sin embargo, una vez entrenada, la inferencia (generación de la heurística) es rápida, lo que permite su uso dentro del bucle de ACO. La arquitectura debe ser inductiva (como GraphSAGE) para generalizar a nuevas instancias del problema.
Regla de Actualización de Feromona	Basada en variantes como Ant System (AS), Ant Colony System (ACS) o Max-Min Ant System (MMAS). El rastro de feromonas se basa en la calidad de las soluciones completas encontradas por las hormigas.	Se mantienen los mecanismos de actualización de feromonas de las variantes de ACO más	La feromona sigue siendo un mecanismo de aprendizaje específico de la instancia crucial. DeepACO y otros enfoques no reemplazan la feromona, sino que la aumentan con una	Heterogeneous multi-agent task allocation based on graph https://www.researchgate.net/publication/375125851_Heterogeneous_multi-agent_task_allocation_based_on_graph_neural_network_ant_colony_optimization_algorithms	Es crucial equilibrar la influencia de la feromona y la heurística GNN mediante los parámetros α y β . Un α alto confiará más en la GNN, mientras que un β alto confiará más en la experiencia pasada de la colonia para esa instancia específica.

		avanzadas. La feromona y la heurística aprendida por la GNN colaboran en la regla de decisión, combinando el aprendizaje a largo plazo (feromona) con la guía estructural instantánea (GNN).	heurística más inteligente. La combinación de la memoria a largo plazo (feromona) y la guía inteligente (GNN) es sinérgica.		
Manejo de Restricciones	Las restricciones duras se manejan típicamente mediante la poda del espacio de búsqueda (las hormigas solo pueden tomar decisiones factibles). Las restricciones blandas se incorporan en la función de coste que evalúa la calidad de la solución final.²²	Las restricciones duras pueden ser "aprendidas" por la GNN como patrones estructurales a evitar. Las restricciones blandas se	Las GNNs pueden aprender a predecir la factibilidad de soluciones. Al entrenar con una función de recompensa basada en el coste de las restricciones blandas, la GNN aprende una política que optimiza directamente la calidad del horario, en lugar de	Graph Neural Networks for the Offline Nanosatellite Task Scheduling Problem - arXivhttps://arxiv.org/pdf/2303.13773 Combining Reinforcement Learning and Constraint Programming for Combinatorial Optimizationhttps://ojs.aaai.org/index.php/AAAI/article/view/16484/16291	Se recomienda un enfoque de dos niveles: usar la GNN para guiar la construcción hacia soluciones de bajo coste, y mantener un "constraint fence layer" ²² o un verificador de factibilidad para garantizar que las restricciones duras nunca se violen, podando las decisiones que la GNN pueda proponer erróneamente.

		convierten en la señal de recompensa para el entrenamiento por refuerzo o en el objetivo de la función de pérdida en el aprendizaje supervisado. La GNN aprende a construir soluciones que inherentement e minimizan las violaciones de restricciones blandas.	seguir reglas manuales indirectas.		
Arquitectura GNN	N/A	GraphSAGE u otra GNN inductiva con múltiples capas de paso de	GraphSAGE es ideal por su naturaleza inductiva, esencial para generalizar a nuevas instancias de problemas.Las	Combinatorial Optimization and Reasoning with Graph Neural Networks, acceso: https://jmlr.org/papers/v24/21-0449.html ACE Applied and	Comenzar con una arquitectura simple (2-3 capas de GraphSAGE) y aumentar la complejidad si es necesario. La calidad de los datos y la representación del grafo son más

		mensajes y funciones de agregación (e.g., mean, max, LSTM). La arquitectura debe ser capaz de manejar grafos heterogéneos.	arquitecturas basadas en atención (Graph Attention Networks - GATs) también son una opción poderosa para ponderar la importancia de diferentes vecinos al agregar información.	Computational Engineering, acceso: https://www.ewadirect.com/proceedings/ace/volumes/vol/111/520.pdf Neural Combinatorial Optimization for Stochastic Flexible Job Shop Scheduling Problems - AAAI Publications https://ojs.aaai.org/index.php/AAAI/article/view/34870/37025	importantes que una arquitectura excesivamente compleja. El sobreajuste es un riesgo si el conjunto de datos de entrenamiento no es suficientemente grande y diverso.
Paradigma de Entrenamiento GNN	N/A	Aprendizaje por Refuerzo (RL) es el enfoque más flexible y potente. El sistema ACO+GNN actúa como un agente que aprende una política de construcción para maximizar una	El RL, como se usa en DeepACO, permite al modelo descubrir heurísticas novedosas sin estar limitado por soluciones existentes. El SL es más simple de implementar pero su rendimiento está acotado por la calidad de los datos de entrenamiento. La tendencia en optimización combinatoria neuronal se inclina hacia el RL	Generalize a Small Pre-trained Model to Arbitrarily Large TSP Instances - AAAI Publications, acceso https://ojs.aaai.org/index.php/AAAI/article/view/16916/16723 Graph Reinforcement Learning for Combinatorial Optimization: A Survey and Unifying Perspective - arXiv https://arxiv.org/html/2404.06492v2 DeepACO: Neural-enhanced Ant Systems for Combinatorial	El entrenamiento con RL es computacionalmente muy costoso y puede ser inestable. Requiere una cuidadosa ingeniería de la recompensa y una sintonización de los hiperparámetros del algoritmo de RL (e.g., REINFORCE con una línea de base para reducir la varianza). El SL puede ser un buen punto de partida para pre-entrenar el modelo.

		recompensa (calidad del horario). El Aprendizaje Supervisado (SL) es una alternativa si se dispone de un gran conjunto de datos de soluciones de alta calidad.	por su mayor potencial.	https://proceedings.neurips.cc/paper_files/paper/2023/file/883105b282fe15275991b411e6b200c5-Paper-Conference.pdf	
Hibridación Adicional	A menudo se hibrida con algoritmos de Búsqueda Local (BL) para mejorar la explotación. ACO construye una solución y BL la refina. ²⁷	Se recomienda un pipeline de tres fases: 1) Construcción con ACO+GraphSAGE para generar una solución inicial de alta calidad. 2) Refinamiento con un algoritmo de	La literatura sobre metaheurísticas muestra consistentemente que la combinación de exploración (algoritmos poblacionales como ACO) y explotación (búsqueda local) produce los mejores resultados. El enfoque neuronal mejora la fase de construcción, pero la fase de refinamiento sigue siendo	Socha course timetabling benchmark datasets Download Table - ResearchGate https://www.researchgate.net/figure/Socha-course-timetabling-benchmark-datasets_tbl1_273311060 Hybrid VNS-TS heuristics for University Course Timetabling Problem - ResearchGate https://www.researchgate.net/publication/341360241_Hybrid_VNS-TS_heuristics_for_University_Course_Timetabling_Problem	La búsqueda local debe ser rápida y eficiente. Se pueden usar movimientos de vecindad simples (e.g., mover una clase a otra franja horaria, intercambiar dos clases). La GNN también podría ser entrenada para guiar la búsqueda local (Learning Improvement Heuristics), aunque esto añade una capa adicional de complejidad.

		Búsqueda Local para alcanzar un óptimo local.	beneficiosa.		
--	--	---	--------------	--	--